

ĐẠI HỌC PHENIKAA
TRƯỜNG CÔNG NGHỆ THÔNG TIN PHENIKAA



BÁO CÁO BÀI TẬP LỚN MÔN XỬ LÝ NGÔN NGỮ TỰ NHIÊN

ĐỀ TÀI:

**PHÂN TÍCH CẢM XÚC VĂN BẢN TÀI CHÍNH VÀ ỨNG DỤNG
TRÊN BÁO CÁO THƯỜNG NIÊN CỦA DOANH NGHIỆP**

Giảng viên hướng dẫn : *ThS. Nguyễn Văn Sơn*

Nhóm : 7

Sinh viên thực hiện : Nguyễn Tùng Dương – 24100358

Ngô Quang Thiện - 24102651

Phạm Thế Duy - 24100583

Khoá : K18

Lớp tín chỉ : CSE703065-2-3-25(N01)

Hà Nội, 2026

PHÂN CÔNG CÔNG VIỆC

Thành viên	Vai trò chính	Công việc	Tỷ trọng
Nguyễn Tùng Dương	Dữ liệu, tiền xử lý và ứng dụng	Thu thập dữ liệu, kiểm tra nhãn, tiền xử lý, EDA, chia dữ liệu, viết phần phương pháp và thiết kế demo ứng dụng	33%
Phạm Thế Duy	Mô hình và đánh giá	Xây dựng baseline, huấn luyện, lựa chọn mô hình, đánh giá test, confusion matrix	33%
Ngô Quang Thiện	Báo cáo và trình bày	Tích hợp phần báo cáo PDF, trực quan hóa, xây dựng slide, chuẩn bị bảo vệ và kiểm tra bản cuối	33%

LỜI CẢM ƠN

Nhóm 7 chúng em xin chân thành cảm ơn ThS. Nguyễn Văn Sơn - Giảng viên học phần Xử lý Ngôn ngữ Tự nhiên đã tận tình giảng dạy, hướng dẫn và hỗ trợ chúng em trong suốt quá trình thực hiện bài tập lớn. Những kiến thức và góp ý của thầy là nền tảng quan trọng giúp nhóm hoàn thành đề tài.

Do thời gian và kiến thức còn hạn chế, báo cáo không tránh khỏi những thiếu sót. Nhóm 7 chúng em rất mong nhận được những ý kiến đóng góp của thầy/cô để hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

TÓM TẮT

Sự bùng nổ của thị trường tài chính đòi hỏi các nhà đầu tư phải xử lý một lượng lớn thông tin từ các báo cáo thường niên và tin tức kinh tế. Việc đọc hiểu và đánh giá thủ công các tài liệu này không chỉ tiêu tốn thời gian mà còn dễ bị ảnh hưởng bởi tâm lý chủ quan. Để giải quyết vấn đề này, đề tài "**Phân tích cảm xúc văn bản tài chính và ứng dụng trên báo cáo thường niên của doanh nghiệp**" được thực hiện nhằm xây dựng một hệ thống Trí tuệ nhân tạo có khả năng tự động đọc hiểu và phân loại cực tính cảm xúc (Tích cực, Tiêu cực, Trung tính) của các câu văn chuyên ngành tài chính.

Nghiên cứu sử dụng bộ dữ liệu chuẩn mực Financial PhraseBank và tiến hành xây dựng một đường ống (pipeline) xử lý ngôn ngữ tự nhiên (NLP) hoàn chỉnh. Các kỹ thuật tiền xử lý đặc thù (như đánh dấu từ phủ định, chuẩn hóa số liệu và tiền tệ) kết hợp cùng thuật toán biểu diễn đặc trưng TF-IDF N-gram đã được áp dụng để giữ lại tối đa ngữ nghĩa của câu. Để khắc phục hiện tượng thiên lệch dữ liệu (imbalanced data), nhóm tiến hành thực nghiệm và tinh chỉnh siêu tham số trên 4 mô hình học máy cơ sở. Kết quả cho thấy mô hình **Logistic Regression** đạt hiệu năng vượt trội nhất với độ chuẩn xác tổng thể (Accuracy) đạt **85.71%** và chỉ số cân bằng **Macro-F1** đạt **81.00%**.

Không chỉ dừng lại ở lý thuyết, giá trị cốt lõi của đề tài nằm ở việc tích hợp thành công mô hình vào một **Ứng dụng Web tự động**. Ứng dụng này cho phép trích xuất văn bản trực tiếp từ các file Báo cáo thường niên (PDF), sau đó bóc tách, chấm điểm và trực quan hóa toàn cảnh "nhiệt kế cảm xúc" của doanh nghiệp. Thành quả của đề tài là tiền đề quan trọng để tiếp tục mở rộng nghiên cứu sang các kiến trúc học sâu (Deep Learning) và triển khai cho hệ thống dữ liệu báo cáo tài chính tại thị trường chứng khoán Việt Nam trong tương lai.

MỤC LỤC

PHÂN CÔNG CÔNG VIỆC	2
LỜI CẢM ƠN.....	3
TÓM TẮT.....	4
MỤC LỤC	5
DANH MỤC TỪ VIẾT TẮT	9
DANH MỤC BẢNG	11
DANH MỤC HÌNH.....	12
CHƯƠNG 1: MỤC TIÊU.....	13
1.1. Giới thiệu đề tài	13
1.2. Mục tiêu đề tài	13
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT.....	15
2.1. Tổng quan NLP.....	15
2.2. Phân loại văn bản	15
2.3. Phân tích cảm xúc tài chính	15
2.4. Tiền xử lý văn bản	16
2.5. N-gram và TF-IDF	18
2.5.1. N-gram:.....	18
2.5.2. TF-IDF:.....	19
2.5.3. Kết hợp TF-IDF với N-gram	21
2.6. Các mô hình phân loại	21
2.6.1. Dummy Classifier.....	22

2.6.2. Naive Bayes	22
2.6.3. Logistic Regression	23
2.6.4. Linear Support Vector Machine (Linear SVM)	24
2.6.5. Nhận xét.....	25
2.7. Các chỉ số đánh giá	25
2.7.1. Accuracy	25
2.7.2. Precision	26
2.7.3. Recall	26
2.7.4. F1-score	26
2.7.5. Classification Report	27
2.7.6. Confusion Matrix.....	27
2.7.7. Vai trò của các chỉ số đánh giá trong đề tài.....	27
2.7.8. Data leakage và Domain shift.....	28
CHƯƠNG 3. XÂY DỰNG HỆ THỐNG PHÂN TÍCH CẢM XÚC	29
3.1. Bộ dữ liệu Financial PhraseBank.....	29
3.1.1. Giới thiệu bộ dữ liệu.....	29
3.1.2. Đặc điểm dữ liệu và Quy trình gán nhãn.....	30
3.1.3. Thống kê tập dữ liệu.....	30
3.2. Tiền xử lý dữ liệu (Data Preprocessing)	31
3.3. Biểu diễn dữ liệu (Data Representation).....	31
3.4. Xây dựng các mô hình	32
3.4.1. Dummy Classifier.....	32
3.4.2. Naive Bayes (Multinomial Naive Bayes).....	33

3.4.3. Logistic Regression	33
3.4.4. Linear SVM (Support Vector Machine).....	33
3.5. Đánh giá và kiểm định hệ thống	34
3.5.1. Accuracy (Độ chính xác tổng thể).....	34
3.5.2. Precision (Độ chuẩn xác).....	34
3.5.3. Recall (Độ bao phủ).....	34
3.5.4. F1-score	35
3.5.5. Classification Report (Báo cáo phân loại chi tiết).....	35
3.5.6. Confusion Matrix (Ma trận nhầm lẫn)	35
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ	35
4.1. Môi trường và dữ liệu thực nghiệm	35
4.2. Kết quả của các mô hình.....	40
4.2.1. Dummy Classifier.....	40
4.2.2. Naive Bayes	41
4.2.3. Logistic Regression	41
4.2.4. Linear SVM	41
4.3. So sánh kết quả giữa các mô hình.....	42
4.4 Đánh giá trên tập Kiểm thử (Test Evaluation).....	46
4.5. Phân tích lỗi (Error Analysis)	50
4.5.1. Các cặp nhầm lẫn phổ biến nhất.....	50
4.5.2. Lỗi theo đặc trưng ngôn ngữ	51
4.5.3. Lỗi theo độ dài câu	51
4.6. Ứng dụng thực tiễn: Đánh giá cảm xúc trên Báo cáo thường niên.....	52

4.6.1. Quy trình xử lý tự động	52
4.6.2. Phân tích kết quả trên PDF	53
4.7. Đóng gói Mô hình và Triển khai Sản phẩm phần mềm trên môi trường Web.....	53
4.7.1. Kiến trúc hệ thống (System Architecture).....	53
4.7.2. Giao diện và Luồng người dùng (User Flow)	56
4.7.3. Hạn chế và Hướng phát triển của Sản phẩm	59
CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	60
5.1. Kết luận.....	60
5.2. Hạn chế của đề tài.....	61
5.3. Hướng phát triển	61
TÀI LIỆU THAM KHẢO	63

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Ý nghĩa	Giải thích
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
EDA	Exploratory Data Analysis	Phân tích dữ liệu khám phá
TF-IDF	Term Frequency - Inverse Document Frequency	Biểu diễn văn bản dựa trên tần suất và độ hiếm tương đối
SVM	Support Vector Machine	Mô hình phân loại tuyến tính phù hợp dữ liệu nhiều chiều
BERT	Bidirectional Encoder Representations from Transformers	Mô hình Transformer học biểu diễn ngữ cảnh
FinBERT	Financial BERT	Biến thể BERT cho miền tài chính
F1-score	Harmonic mean of Precision and Recall	Chỉ số cân bằng giữa Precision và Recall

Link GitHub: <https://github.com/ngtd-2609/financial-sentiment-analysis-app.git>

DANH MỤC BẢNG

Bảng 4.1.1: Thống kê dữ liệu Financial PhraseBank	36
Bảng 4.1.2: Thống kê tổng quan các đặc trưng của bộ dữ liệu sau tiền xử lý.	38
Bảng 4.1.3: Thống kê chi tiết tỷ lệ chia tách dữ liệu và phân bố nhãn.	39
Bảng 4.1.4: Bảng tổng hợp cấu hình kỹ thuật của hệ thống phân loại.....	40
Bảng 4.3.1: So sánh tổng quát trên tập VALIDATION	43
Bảng 4.3.2: chi tiết theo từng lớp (negative / neutral / positive) trên VALIDATION.....	44
Bảng 4.4.1: Kết quả TEST cho mô hình tốt nhất (Logistic Regression).....	46
Bảng 4.4.2: Chi tiết theo từng lớp trên TEST(Logistic Regression).....	47
Bảng 4.5.1: Thống kê các kiểu nhầm lẫn xuất hiện nhiều nhất.....	51
Bảng 4.5.3: Phân phối tỷ lệ nhầm lẫn.....	52
Bảng 4.7.1 Vai trò của các tệp chính trong sản phẩm	55
Bảng 4.7.2 Các chỉ số đánh giá được hiển thị trong ứng dụng	58

DANH MỤC HÌNH

Hình 4.1.1. Phân bố nhãn trong dữ liệu ban đầu	37
Hình 4.1.2. Phân bố độ dài câu.....	38
Hình 4.1.3. Độ dài câu theo nhãn	39
Hình 4.3.1: Trực quan hóa chỉ số Macro-F1 và Accuracy giữa các mô hình trên tập Validation.	45
Hình 4.3.2: Trực quan hóa chi tiết hiệu năng nhận diện từng phân lớp (Negative, Neutral, Positive) của các mô hình cơ sở.	45
Hình 4.4.1: Confusion Matrix theo số lượng – Logistic Regression.....	48
Hình 4.4.2: Confusion Matrix theo tỷ lệ hàng – Logistic Regression	49
Hình 4.7.1. Kiến trúc tổng thể của hệ thống phân tích cảm xúc tài chính	54
Hình 4.8.2 Giao diện tổng quan của ứng dụng Web Financial Sentiment Analysis	56

CHƯƠNG 1: MỤC TIÊU

1.1. Giới thiệu đề tài

Trong những năm gần đây, sự phát triển của trí tuệ nhân tạo (Artificial Intelligence - AI) và xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) đã mở ra nhiều hướng tiếp cận mới trong việc khai thác và phân tích dữ liệu văn bản. Một trong những ứng dụng nổi bật của NLP là phân tích cảm xúc (Sentiment Analysis), cho phép tự động xác định thái độ hoặc xu hướng được thể hiện trong văn bản. Phương pháp này được ứng dụng rộng rãi trong nhiều lĩnh vực như thương mại điện tử, truyền thông, chăm sóc khách hàng và đặc biệt là tài chính.

Trong lĩnh vực tài chính, các nguồn dữ liệu như báo cáo tài chính, báo cáo thường niên, tin tức và thông cáo báo chí chứa nhiều thông tin quan trọng phản ánh tình hình hoạt động, hiệu quả kinh doanh và triển vọng phát triển của doanh nghiệp. Tuy nhiên, khối lượng dữ liệu lớn cùng cách diễn đạt mang tính chuyên môn khiến việc phân tích thủ công trở nên tốn nhiều thời gian và khó đảm bảo tính nhất quán. Do đó, việc ứng dụng các kỹ thuật NLP để tự động phân tích cảm xúc từ văn bản tài chính có ý nghĩa quan trọng trong việc hỗ trợ đánh giá doanh nghiệp và ra quyết định.

Trong đề tài này, bài toán phân tích cảm xúc được xây dựng trên tập dữ liệu **Financial PhraseBank**, bao gồm các câu văn tài chính được gán nhãn **Positive**, **Neutral** và **Negative**. Văn bản sau khi được tiền xử lý sẽ được biểu diễn bằng phương pháp **TF-IDF** kết hợp với **N-gram** đối với các mô hình học máy truyền thống. Kết quả của các mô hình được đánh giá và so sánh thông qua các chỉ số như **Accuracy**, **Precision**, **Recall** và **F1-score**, đồng thời thử nghiệm trên dữ liệu trích xuất từ báo cáo thường niên để đánh giá khả năng ứng dụng trong thực tế.

1.2. Mục tiêu đề tài

Đề tài được thực hiện nhằm xây dựng và đánh giá hệ thống phân tích cảm xúc cho văn bản tài chính bằng các phương pháp xử lý ngôn ngữ tự nhiên và học máy. Các mục tiêu cụ thể bao gồm:

- Nghiên cứu cơ sở lý thuyết về xử lý ngôn ngữ tự nhiên, phân loại văn bản và phân tích cảm xúc trong lĩnh vực tài chính.
- Tiền xử lý và chuẩn hóa dữ liệu văn bản nhằm nâng cao chất lượng dữ liệu đầu vào cho mô hình.
- Biểu diễn văn bản bằng phương pháp **TF-IDF** kết hợp với **N-gram** đối với các mô hình học máy truyền thống.
- Xây dựng và huấn luyện các mô hình **Naive Bayes**, **Logistic Regression** và **Linear Support Vector Machine (Linear SVM)** để thực hiện bài toán phân tích cảm xúc.
- Đánh giá và so sánh hiệu quả của các mô hình thông qua các chỉ số **Accuracy**, **Precision**, **Recall**, **F1-score** và **Confusion Matrix**.
- Áp dụng mô hình đã huấn luyện để phân tích cảm xúc trên nội dung của **báo cáo thường niên doanh nghiệp**, từ đó đánh giá khả năng ứng dụng của mô hình trên dữ liệu tài chính thực tế.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

2.1. Tổng quan NLP

Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) là lĩnh vực kết hợp giữa trí tuệ nhân tạo (Artificial Intelligence - AI), học máy (Machine Learning - ML) và ngôn ngữ học (Linguistics) nhằm giúp máy tính hiểu, phân tích, xử lý và tạo ra ngôn ngữ của con người. Mục tiêu của NLP là thu hẹp khoảng cách giữa ngôn ngữ tự nhiên và ngôn ngữ máy, cho phép máy tính tương tác với con người một cách hiệu quả hơn thông qua văn bản hoặc lời nói.

Khác với dữ liệu có cấu trúc, ngôn ngữ tự nhiên thường chứa nhiều đặc điểm phức tạp như đa nghĩa, đồng nghĩa, phụ thuộc ngữ cảnh và sự khác biệt về cú pháp giữa các ngôn ngữ. Vì vậy, NLP sử dụng nhiều kỹ thuật từ tiền xử lý văn bản, biểu diễn dữ liệu, học máy đến học sâu để trích xuất thông tin và xây dựng các mô hình xử lý ngôn ngữ.

2.2. Phân loại văn bản

Phân loại văn bản (Text Classification) là một bài toán cốt lõi trong Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP), nhằm tự động gán một hoặc nhiều nhãn cho văn bản dựa trên nội dung của nó. Mục tiêu của phương pháp này là giúp máy tính nhận diện chủ đề, ý nghĩa hoặc mục đích của văn bản, từ đó hỗ trợ tổ chức, tìm kiếm và khai thác thông tin một cách hiệu quả.

Trong bài toán phân loại văn bản, mô hình được huấn luyện từ tập dữ liệu đã gán nhãn để học mối quan hệ giữa đặc trưng của văn bản và nhãn tương ứng. Sau khi huấn luyện, mô hình có thể dự đoán nhãn cho các văn bản mới chưa từng xuất hiện. Đây là một bài toán học có giám sát (Supervised Learning) được ứng dụng rộng rãi trong nhiều lĩnh vực.

2.3. Phân tích cảm xúc tài chính

Phân tích cảm xúc tài chính (Financial Sentiment Analysis) là một nhánh của phân tích cảm xúc (Sentiment Analysis) trong Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP), tập trung vào việc xác định và đánh giá cảm xúc, quan điểm hoặc xu

hướng được thể hiện trong các văn bản tài chính. Mục tiêu của phương pháp này là khai thác thông tin định tính từ dữ liệu văn bản để hỗ trợ dự báo thị trường, đánh giá doanh nghiệp và ra quyết định đầu tư.

Không giống các bài toán phân tích cảm xúc thông thường trên mạng xã hội hoặc đánh giá sản phẩm, dữ liệu tài chính chủ yếu được lấy từ báo cáo tài chính, báo cáo thường niên, báo cáo quản trị, thông cáo báo chí, tin tức tài chính và các bài phân tích thị trường. Các tài liệu này sử dụng ngôn ngữ mang tính chuyên môn, khách quan và chứa nhiều thuật ngữ đặc thù, khiến việc xác định cảm xúc trở nên phức tạp hơn.

Trong lĩnh vực tài chính, cảm xúc không chỉ được phân loại thành tích cực (Positive), tiêu cực (Negative) và trung lập (Neutral) mà còn phản ánh triển vọng hoạt động, mức độ rủi ro, khả năng tăng trưởng và niềm tin của thị trường đối với doanh nghiệp. Do đó, kết quả phân tích cảm xúc có thể được sử dụng như một nguồn thông tin bổ sung bên cạnh các chỉ số tài chính truyền thống.

2.4. Tiền xử lý văn bản

Tiền xử lý văn bản (Text Preprocessing) là giai đoạn đầu tiên trong quy trình xử lý ngôn ngữ tự nhiên (NLP), nhằm chuyển đổi dữ liệu văn bản thô thành dữ liệu có chất lượng và phù hợp cho quá trình huấn luyện mô hình. Dữ liệu thu thập từ các báo cáo tài chính hoặc tập dữ liệu thường chứa nhiều thành phần không cần thiết như khoảng trắng dư thừa, ký tự đặc biệt hoặc các định dạng không đồng nhất. Nếu không được xử lý trước, những yếu tố này có thể làm tăng nhiễu, giảm chất lượng đặc trưng và ảnh hưởng đến hiệu quả của mô hình phân loại.

Trong bài toán phân tích cảm xúc tài chính, mục tiêu của tiền xử lý không chỉ là làm sạch dữ liệu mà còn bảo toàn các thông tin mang giá trị ngữ nghĩa như số liệu, tỷ lệ phần trăm, đơn vị tiền tệ và các từ phủ định. Những thành phần này thường phản ánh trực tiếp kết quả hoạt động kinh doanh hoặc mức độ tích cực, tiêu cực của nội dung tài chính. Vì vậy, quy trình tiền xử lý được thiết kế theo hướng chuẩn hóa dữ liệu nhưng vẫn giữ lại các thông tin quan trọng phục vụ quá trình phân loại.

- Chuẩn hóa văn bản:

Chuẩn hóa văn bản giúp đưa toàn bộ dữ liệu về cùng một định dạng trước khi trích xuất đặc trưng. Trong đề tài này, các thao tác chuẩn hóa bao gồm:

- + Chuyển toàn bộ văn bản về chữ thường (lowercase) để tránh coi cùng một từ ở các kiểu viết khác nhau là các đặc trưng riêng biệt.
- + Chuẩn hóa mã hóa Unicode nhằm đảm bảo các ký tự được biểu diễn thống nhất.
- + Loại bỏ khoảng trắng thừa và các ký tự xuống dòng không cần thiết.
- + Chuẩn hóa cách biểu diễn văn bản để giảm sự không đồng nhất trong dữ liệu.
- + Những thao tác này giúp giảm số lượng đặc trưng dư thừa và cải thiện chất lượng biểu diễn văn bản.

- Loại bỏ ký tự không cần thiết:

Văn bản tài chính thường chứa nhiều ký tự không mang giá trị trong quá trình phân loại như dấu câu, ký tự đặc biệt hoặc các ký hiệu định dạng. Các thành phần này được loại bỏ nhằm giảm nhiễu và đơn giản hóa dữ liệu.

Tuy nhiên, khác với nhiều bài toán NLP thông thường, đề tài không loại bỏ các giá trị số, ký hiệu phần trăm (%) và ký hiệu tiền tệ (\$, €, £,...) vì đây là những thông tin có ý nghĩa quan trọng trong lĩnh vực tài chính. Chẳng hạn, các cụm từ như "*profit increased by 20%*" hoặc "*revenue reached \$5 million*" đều chứa các chỉ số phản ánh trực tiếp kết quả kinh doanh của doanh nghiệp.

- Bảo toàn từ phủ định:

Các từ phủ định như not, no, never hoặc without có ảnh hưởng lớn đến ý nghĩa của câu. Việc loại bỏ các từ này có thể làm thay đổi hoàn toàn sắc thái cảm xúc của văn bản.

Ví dụ:

The company is profitable. (Công ty hoạt động có lãi.)

The company is not profitable. (Công ty không có lãi.)

Mặc dù chỉ khác một từ, hai câu trên mang ý nghĩa trái ngược. Vì vậy, trong quá trình tiền xử lý, các từ phủ định được giữ nguyên để mô hình có thể học chính xác ngữ nghĩa của văn bản.

- **Tiền xử lý đối với các mô hình khác nhau:**

Trong đề tài này, dữ liệu được sử dụng cho hai nhóm mô hình khác nhau nên quy trình tiền xử lý cũng có sự khác biệt.

Đối với các mô hình học máy truyền thống như Naive Bayes, Logistic Regression và Linear SVM, văn bản được chuẩn hóa trước khi chuyển sang bước biểu diễn đặc trưng bằng TF-IDF. Việc làm sạch dữ liệu giúp giảm nhiễu và nâng cao chất lượng của ma trận đặc trưng.

- **Vai trò của tiền xử lý văn bản:**

Tiền xử lý văn bản là bước nền tảng trong toàn bộ hệ thống phân tích cảm xúc. Một quy trình tiền xử lý phù hợp giúp chuẩn hóa dữ liệu, giảm nhiễu, bảo toàn các thông tin tài chính quan trọng và tạo ra đầu vào chất lượng cho quá trình trích xuất đặc trưng cũng như huấn luyện mô hình. Nhờ đó, các mô hình phân loại có thể khai thác tốt hơn thông tin ngữ nghĩa trong văn bản và nâng cao độ chính xác của kết quả phân tích cảm xúc.

2.5. N-gram và TF-IDF

2.5.1. N-gram:

N-gram là kỹ thuật biểu diễn văn bản bằng cách chia chuỗi từ thành các nhóm gồm N từ liên tiếp. Thay vì chỉ xem xét từng từ riêng lẻ, N-gram giúp mô hình khai thác mối quan hệ giữa các từ liên kề, từ đó biểu diễn tốt hơn ngữ cảnh của văn bản.

Trong thực tế, **Unigram** và **Bigram** là hai dạng được sử dụng phổ biến nhất vì chúng cân bằng giữa khả năng biểu diễn ngữ cảnh và chi phí tính toán.

Việc sử dụng N-gram giúp mô hình không chỉ quan tâm đến sự xuất hiện của từng từ mà còn xem xét mối quan hệ giữa các từ trong câu. Điều này đặc biệt hữu ích trong bài toán phân tích cảm xúc, khi ý nghĩa của một cụm từ thường khác với ý nghĩa của từng từ riêng lẻ.

- Ưu điểm của N-gram:
 - + Biểu diễn được mối quan hệ giữa các từ liên tiếp.
 - + Cải thiện khả năng nắm bắt ngữ cảnh so với chỉ sử dụng Unigram.
 - + Dễ triển khai và tương thích với các phương pháp biểu diễn văn bản như **Bag of Words** và **TF-IDF**.
 - + Phù hợp với các mô hình học máy truyền thống như Naive Bayes, Logistic Regression và SVM.
- Hạn chế:
 - + Khi giá trị **N** tăng, số lượng đặc trưng tăng rất nhanh, làm tăng chi phí lưu trữ và tính toán.
 - + Dữ liệu trở nên thưa (Sparse Data), đặc biệt đối với Trigram hoặc các N-gram có bậc cao.
 - + Chỉ phản ánh mối quan hệ cục bộ giữa các từ liên tiếp, chưa thể biểu diễn đầy đủ ngữ nghĩa của toàn bộ câu.

2.5.2. TF-IDF:

TF-IDF (Term Frequency – Inverse Document Frequency) là phương pháp biểu diễn văn bản phổ biến trong xử lý ngôn ngữ tự nhiên. Phương pháp này chuyển đổi văn bản thành các vector số bằng cách đánh giá mức độ quan trọng của từng từ trong một tài liệu so với toàn bộ tập dữ liệu.

Khác với Bag of Words, TF-IDF không chỉ dựa trên số lần xuất hiện của từ trong văn bản mà còn giảm trọng số của những từ xuất hiện quá phổ biến trong nhiều tài liệu. Nhờ đó, các từ mang nhiều thông tin phân biệt sẽ được gán trọng số cao hơn.

- **Term Frequency (TF):**

TF biểu thị tần suất xuất hiện của một từ trong một văn bản.

Công thức:

$$TF(t, d) = \frac{f(t, d)}{\sum_{t'} f(t', d)}$$

Trong đó:

$$\begin{aligned} f(t, d): & \text{ số lần từ } t \text{ xuất hiện trong văn bản } d, \\ \sum_{t'} f(t', d): & \text{ tổng số từ trong văn bản } d. \end{aligned}$$

TF càng lớn chứng tỏ từ đó càng quan trọng đối với văn bản đang xét.

- **Inverse Document Frequency (IDF):**

IDF đo mức độ phổ biến của một từ trong toàn bộ tập dữ liệu.

Công thức:

$$IDF(t) = \log\left(\frac{N}{df(t)}\right)$$

Trong đó:

$$\begin{aligned} N: & \text{ tổng số văn bản,} \\ df(t): & \text{ số văn bản chứa từ } t. \end{aligned}$$

- **Trọng số TF-IDF:**

Giá trị TF-IDF được tính bằng tích của TF và IDF:

$$TF-IDF(t, d) = TF(t, d) \cdot IDF(t)$$

Trọng số TF-IDF càng cao chứng tỏ từ đó càng quan trọng đối với văn bản và có khả năng phân biệt tốt giữa các lớp dữ liệu.

2.5.3. Kết hợp TF-IDF với N-gram

Trong nhiều bài toán phân loại văn bản, TF-IDF thường được kết hợp với N-gram để khai thác cả thông tin về tần suất xuất hiện và ngữ cảnh giữa các từ.

- Ưu điểm:
 - + Đơn giản, dễ triển khai và có chi phí tính toán thấp.
 - + Giảm ảnh hưởng của các từ xuất hiện quá phổ biến.
 - + Làm nổi bật các từ hoặc cụm từ mang nhiều thông tin.
 - + Hoạt động hiệu quả với các mô hình học máy truyền thống như Naive Bayes, Logistic Regression và Support Vector Machine (SVM).
- Hạn chế:
 - + Không biểu diễn được ý nghĩa ngữ nghĩa của từ.
 - + Không xét đến thứ tự từ nếu chỉ sử dụng Unigram.
 - + Ma trận đặc trưng thường có kích thước lớn và thưa (Sparse Matrix).
 - + Không thể xử lý tốt các từ đồng nghĩa hoặc đa nghĩa.

Trong đề tài này, TF-IDF kết hợp với N-gram (Unigram và Bigram) được sử dụng để chuyển đổi các câu trong tập dữ liệu Financial PhraseBank thành vector đặc trưng. Các vector này được sử dụng làm đầu vào cho các mô hình Naive Bayes, Logistic Regression và Linear SVM nhằm thực hiện bài toán phân tích cảm xúc tài chính. Việc kết hợp N-gram với TF-IDF giúp mô hình vừa khai thác được ngữ cảnh cục bộ giữa các từ, vừa nhấn mạnh các từ và cụm từ có giá trị phân biệt cao, góp phần nâng cao hiệu quả phân loại.

2.6. Các mô hình phân loại

Trong bài toán phân tích cảm xúc tài chính, sau khi văn bản được tiền xử lý và chuyển đổi thành vector đặc trưng, các mô hình phân loại được sử dụng để dự đoán nhãn cảm

xúc của từng câu. Đề tài này sử dụng cả các mô hình học máy truyền thống và mô hình học sâu nhằm đánh giá hiệu quả của từng phương pháp trên tập dữ liệu Financial PhraseBank. Các mô hình được sử dụng bao gồm **Dummy Classifier**, **Naive Bayes**, **Logistic Regression** và **Linear Support Vector Machine (Linear SVM)**.

2.6.1. Dummy Classifier

Dummy Classifier là mô hình phân loại cơ sở (Baseline Model) được sử dụng để tạo ra mức hiệu suất tham chiếu trước khi áp dụng các mô hình học máy. Mô hình này không học từ dữ liệu mà đưa ra dự đoán dựa trên các chiến lược đơn giản như luôn dự đoán lớp xuất hiện nhiều nhất hoặc dự đoán ngẫu nhiên theo phân bố của dữ liệu.

Trong đề tài này, Dummy Classifier được sử dụng để đánh giá xem các mô hình học máy có thực sự học được đặc trưng của dữ liệu hay không. Một mô hình chỉ được xem là hiệu quả khi đạt kết quả cao hơn đáng kể so với mô hình cơ sở.

- Ưu điểm:
 - + Dễ triển khai và có tốc độ thực thi rất nhanh.
 - + Cung cấp mức hiệu suất tham chiếu cho các mô hình khác.
- Nhược điểm:
 - + Không học đặc trưng của dữ liệu.
 - + Không phù hợp để giải quyết bài toán phân loại thực tế.

2.6.2. Naive Bayes

Naive Bayes là thuật toán phân loại dựa trên **định lý Bayes**, với giả thiết rằng các đặc trưng đầu vào độc lập có điều kiện với nhau khi biết trước nhãn lớp. Mặc dù giả thiết này khá đơn giản và hiếm khi hoàn toàn đúng trong thực tế, Naive Bayes vẫn đạt hiệu quả cao trong nhiều bài toán phân loại văn bản.

Xác suất một văn bản thuộc lớp C được tính theo công thức:

$$P(C | X) = \frac{P(X | C) \cdot P(C)}{P(X)}$$

Trong đó:

$P(C | X)$: xác suất văn bản X thuộc lớp C ,

$P(X | C)$: xác suất xuất hiện văn bản X khi biết lớp C ,

$P(C)$: xác suất tiên nghiệm của lớp,

$P(X)$: xác suất xuất hiện của văn bản.

Trong bài toán phân loại văn bản, biến thể **Multinomial Naive Bayes** thường được sử dụng do hoạt động hiệu quả với dữ liệu biểu diễn bằng TF-IDF hoặc Bag of Words.

- Ưu điểm:
 - + Tốc độ huấn luyện và dự đoán nhanh.
 - + Hoạt động tốt trên dữ liệu có số chiều lớn.
 - + Phù hợp với bài toán phân loại văn bản.
- Nhược điểm
 - + Giả thiết độc lập giữa các đặc trưng thường không phản ánh đúng dữ liệu thực tế.
 - + Hiệu quả giảm khi dữ liệu có mối quan hệ ngữ nghĩa phức tạp.

2.6.3. Logistic Regression

Logistic Regression là thuật toán học có giám sát được sử dụng phổ biến trong các bài toán phân loại. Thuật toán ước lượng xác suất một mẫu thuộc vào một lớp thông qua **hàm Sigmoid**, sau đó lựa chọn lớp có xác suất cao nhất.

Hàm Sigmoid được xác định như sau:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Trong đó:

$$z = \mathbf{w}^T \mathbf{x} + b,$$

$\mathbf{w}$: vector trọng số,

b : hệ số dịch chuyển (bias).

Trong bài toán nhiều lớp, Logistic Regression thường được mở rộng bằng phương pháp **One-vs-Rest (OvR)** hoặc **Softmax**.

Khi kết hợp với TF-IDF, Logistic Regression có khả năng học trọng số của từng đặc trưng để phân biệt các lớp cảm xúc.

- Ưu điểm:
 - + Dễ huấn luyện và dễ diễn giải.
 - + Hoạt động tốt trên dữ liệu có số chiều lớn.
 - + Phù hợp với dữ liệu văn bản biểu diễn bằng TF-IDF.
- Nhược điểm:
 - + Chủ yếu mô hình hóa quan hệ tuyến tính giữa đặc trưng và nhãn.
 - + Khả năng biểu diễn ngữ nghĩa còn hạn chế.

2.6.4. Linear Support Vector Machine (Linear SVM)

Support Vector Machine (SVM) là thuật toán phân loại tìm **siêu phẳng (Hyperplane)** tối ưu nhằm phân tách các lớp dữ liệu với khoảng cách (Margin) lớn nhất.

Đối với dữ liệu văn bản có số chiều lớn, **Linear SVM** thường được lựa chọn vì có tốc độ huấn luyện nhanh và đạt hiệu quả cao. Khi kết hợp với TF-IDF, mỗi văn bản được biểu diễn dưới dạng vector đặc trưng và thuật toán sẽ tìm siêu phẳng phân tách tối ưu giữa các lớp cảm xúc.

Mục tiêu của Linear SVM là tối đa hóa khoảng cách giữa siêu phẳng và các điểm dữ liệu gần nhất (Support Vectors), từ đó tăng khả năng tổng quát hóa của mô hình.

- Ưu điểm:
 - + Độ chính xác cao trên bài toán phân loại văn bản.
 - + Hoạt động tốt với dữ liệu nhiều đặc trưng.
 - + Khả năng tổng quát hóa tốt.
- Nhược điểm:
 - + Khó diễn giải hơn Logistic Regression.

- + Không trực tiếp cung cấp xác suất dự đoán.
- + Hiệu quả phụ thuộc vào việc lựa chọn tham số.

2.6.5. Nhận xét

Trong đề tài này, **Naive Bayes**, **Logistic Regression** và **Linear SVM** đại diện cho nhóm mô hình học máy truyền thống, sử dụng đặc trưng **TF-IDF kết hợp với N-gram** để biểu diễn văn bản. **Dummy Classifier** đóng vai trò làm mô hình cơ sở để đánh giá mức cải thiện của các phương pháp học máy.

2.7. Các chỉ số đánh giá

Đánh giá mô hình là bước quan trọng nhằm xác định hiệu quả của mô hình phân loại trên tập dữ liệu kiểm thử. Trong bài toán phân tích cảm xúc tài chính, việc sử dụng nhiều chỉ số đánh giá giúp phản ánh toàn diện khả năng phân loại của mô hình, thay vì chỉ dựa vào độ chính xác tổng thể. Trong **đề tài này**, các mô hình được đánh giá thông qua **Accuracy**, **Precision**, **Recall**, **F1-score**, kết hợp với **Classification Report** và **Confusion Matrix**.

2.7.1. Accuracy

Accuracy (độ chính xác) là tỷ lệ giữa số lượng mẫu được dự đoán đúng và tổng số mẫu trong tập dữ liệu. Đây là chỉ số phản ánh hiệu quả tổng thể của mô hình.

Công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Trong đó:

- TP** (True Positive): số mẫu thuộc lớp dương được dự đoán đúng,
- TN** (True Negative): số mẫu thuộc lớp âm được dự đoán đúng,
- FP** (False Positive): số mẫu thuộc lớp âm nhưng bị dự đoán nhầm là lớp dương,
- FN** (False Negative): số mẫu thuộc lớp dương nhưng bị dự đoán nhầm là lớp âm.

Giá trị Accuracy càng cao cho thấy mô hình có khả năng dự đoán chính xác trên toàn bộ tập dữ liệu. Tuy nhiên, khi dữ liệu mất cân bằng giữa các lớp, Accuracy có thể không phản ánh đúng hiệu quả thực tế của mô hình.

2.7.2. Precision

Precision (độ chính xác dự đoán) đo lường tỷ lệ các mẫu được dự đoán thuộc một lớp và thực sự thuộc lớp đó.

Công thức:

$$Precision = \frac{TP}{TP + FP}$$

Precision cao cho thấy mô hình tạo ra ít dự đoán sai (**False Positive**). Chỉ số này đặc biệt quan trọng khi cần giảm các dự đoán nhầm của mô hình.

2.7.3. Recall

Recall (độ bao phủ) đo lường khả năng phát hiện đúng các mẫu thuộc một lớp.

Công thức:

$$Precision = \frac{TP}{TP + FN}$$

Recall càng cao chứng tỏ mô hình bỏ sót càng ít mẫu (**False Negative**), qua đó nâng cao khả năng nhận diện đầy đủ các văn bản thuộc từng lớp cảm xúc.

2.7.4. F1-score

F1-score là trung bình điều hòa giữa Precision và Recall, được sử dụng để đánh giá sự cân bằng giữa hai chỉ số này.

Công thức:

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

F1-score đặc biệt hữu ích trong các bài toán mà dữ liệu giữa các lớp không cân bằng hoặc khi cần đánh giá đồng thời khả năng dự đoán chính xác và khả năng phát hiện đầy đủ các mẫu của mô hình.

2.7.5. Classification Report

Classification Report là bảng tổng hợp các chỉ số **Precision**, **Recall**, **F1-score** và **Support** của từng lớp dữ liệu.

Trong đó, **Support** là số lượng mẫu thực tế của mỗi lớp trong tập kiểm thử. Báo cáo này giúp đánh giá hiệu quả của mô hình trên từng nhãn cảm xúc (**Positive**, **Neutral**, **Negative**) thay vì chỉ xem xét kết quả tổng thể.

2.7.6. Confusion Matrix

Confusion Matrix (ma trận nhầm lẫn) là bảng thể hiện số lượng mẫu được dự đoán đúng và dự đoán sai giữa các lớp. Mỗi hàng biểu diễn nhãn thực tế, trong khi mỗi cột biểu diễn nhãn dự đoán của mô hình.

Thông qua Confusion Matrix, có thể xác định:

- Số lượng mẫu được phân loại đúng của từng lớp.
- Các trường hợp mô hình dự đoán nhầm giữa các lớp.
- Những lớp mà mô hình còn gặp khó khăn trong quá trình phân loại.

Confusion Matrix không chỉ hỗ trợ phân tích nguyên nhân gây ra sai số mà còn là cơ sở để tính toán các chỉ số Accuracy, Precision, Recall và F1-score.

2.7.7. Vai trò của các chỉ số đánh giá trong đề tài

Trong đề tài này, các mô hình **Naive Bayes**, **Logistic Regression** và **Linear SVM** được đánh giá trên cùng tập kiểm thử bằng các chỉ số **Accuracy**, **Precision**, **Recall** và **F1-score**.

Đồng thời, **Classification Report** và **Confusion Matrix** được sử dụng để phân tích chi tiết kết quả phân loại của từng mô hình đối với ba lớp cảm xúc **Positive**, **Neutral** và **Negative**.

Việc kết hợp nhiều chỉ số đánh giá giúp phản ánh đầy đủ hiệu quả của từng mô hình, từ đó chính xác tổng thể đến khả năng phân biệt từng lớp cảm xúc. Đây là cơ sở để so sánh hiệu năng giữa các mô hình và lựa chọn phương pháp phù hợp cho bài toán phân tích cảm xúc tài chính trong đề tài.

2.7.8. Data leakage và Domain shift

– Data Leakage:

Data Leakage (Rò rỉ dữ liệu) là hiện tượng mô hình vô tình sử dụng thông tin từ tập kiểm thử hoặc những dữ liệu không có sẵn trong quá trình dự đoán thực tế. Điều này làm cho kết quả đánh giá cao hơn so với khả năng tổng quát hóa thực sự của mô hình.

Data Leakage có thể xảy ra trong nhiều giai đoạn của quá trình xây dựng mô hình, chẳng hạn như chuẩn hóa dữ liệu trên toàn bộ tập dữ liệu trước khi chia tập huấn luyện và tập kiểm thử, hoặc xây dựng đặc trưng từ cả dữ liệu huấn luyện và dữ liệu kiểm thử. Khi đó, mô hình đã tiếp cận trước một phần thông tin của tập kiểm thử, dẫn đến kết quả đánh giá không còn khách quan.

Để hạn chế Data Leakage, cần thực hiện các bước tiền xử lý, trích xuất đặc trưng và chuẩn hóa chỉ trên tập huấn luyện. Sau khi các tham số được học từ tập huấn luyện, chúng mới được áp dụng cho tập kiểm thử. Trong đề tài này, việc chia dữ liệu thành tập huấn luyện và tập kiểm thử được thực hiện trước khi huấn luyện mô hình nhằm đảm bảo quá trình đánh giá phản ánh đúng khả năng tổng quát hóa của mô hình.

– Domain Shift:

Domain Shift là hiện tượng phân bố dữ liệu trong quá trình dự đoán khác với phân bố dữ liệu mà mô hình đã được huấn luyện. Sự khác biệt này có thể làm giảm đáng kể hiệu quả của mô hình khi triển khai trên dữ liệu thực tế.

Trong lĩnh vực phân tích cảm xúc tài chính, Domain Shift thường xảy ra khi mô hình được huấn luyện trên một loại dữ liệu nhưng lại được áp dụng cho một nguồn dữ liệu khác. Ví dụ, mô hình được huấn luyện trên các câu ngắn trong tập Financial PhraseBank nhưng được sử dụng để phân tích báo cáo thường niên, báo cáo tài chính hoặc tin tức tài chính có cấu trúc và cách diễn đạt phức tạp hơn. Sự khác biệt về từ vựng, độ dài văn bản và ngữ cảnh có thể làm giảm khả năng phân loại của mô hình.

Để giảm ảnh hưởng của Domain Shift, có thể áp dụng các giải pháp như mở rộng tập dữ liệu huấn luyện, sử dụng dữ liệu đa nguồn hoặc lựa chọn các mô hình ngôn ngữ tiền huấn luyện chuyên biệt cho lĩnh vực tài chính, chẳng hạn như FinBERT. Những mô hình này được huấn luyện trên lượng lớn văn bản tài chính nên có khả năng thích nghi tốt hơn với các dữ liệu cùng miền.

Trong đề tài này, vấn đề Domain Shift được xem xét khi áp dụng các mô hình đã huấn luyện trên tập Financial PhraseBank để phân tích cảm xúc từ các báo cáo thường niên của doanh nghiệp. Do đặc điểm ngôn ngữ giữa hai nguồn dữ liệu có sự khác biệt, kết quả thực nghiệm được đánh giá không chỉ dựa trên độ chính xác mà còn trên khả năng thích nghi của mô hình đối với dữ liệu thực tế.

CHƯƠNG 3. XÂY DỰNG HỆ THỐNG PHÂN TÍCH CẢM XÚC

3.1. Bộ dữ liệu Financial PhraseBank

3.1.1. Giới thiệu bộ dữ liệu

Financial PhraseBank là một bộ dữ liệu chuẩn mực (benchmark dataset) cực kỳ phổ biến trong các bài toán Xử lý ngôn ngữ tự nhiên (NLP) áp dụng cho lĩnh vực tài chính. Bộ dữ liệu này được xây dựng và công bố bởi nhóm nghiên cứu Malo, Sinha, Korhonen, Wallenius, và Takala vào năm 2014 (Đại học Aalto, Phần Lan). Mục tiêu cốt lõi của bộ dữ liệu là phân loại cảm xúc (sentiment) của các câu văn được trích xuất từ các tin tức tài

chính tiếng Anh, chủ yếu liên quan đến các công ty niêm yết trên sàn giao dịch chứng khoán.

3.1.2. Đặc điểm dữ liệu và Quy trình gán nhãn

Nguồn dữ liệu: Khoảng 4,840 câu văn được trích xuất từ các bản tin tài chính tiếng Anh.

Quy tắc gán nhãn: Các câu được đánh giá bởi 16 chuyên gia (chủ yếu là sinh viên, nhà nghiên cứu thuộc khối ngành tài chính, kinh tế, kế toán). Họ được yêu cầu đóng vai một nhà đầu tư nhỏ lẻ để phân tích xem thông tin trong câu văn đó có khả năng tác động tích cực, tiêu cực hay không tác động (trung tính) đến giá cổ phiếu của doanh nghiệp.

Mức độ đồng thuận (Agreement Level): Vì mỗi câu được đánh giá bởi 5-8 người khác nhau, bộ dữ liệu cung cấp nhiều tập con (sub-datasets) dựa trên mức độ đồng thuận của người gán nhãn. Cấu hình được sử dụng trong đề tài này là Sentences_75Agree, tức là tập hợp các câu có từ 75% số người gán nhãn trở lên đồng ý với nhau về cùng một nhãn cảm xúc. Điều này giúp loại bỏ những câu có ngữ nghĩa quá mập mờ.

3.1.3. Thống kê tập dữ liệu

Dựa trên việc đọc trực tiếp file dữ liệu, cấu hình 75% đồng thuận có tổng cộng **3,453 câu**, được phân chia thành 3 lớp (classes) mất cân bằng (imbalanced) như sau:

- **Positive (Tích cực):** 887 mẫu (~25.7%)
- **Negative (Tiêu cực):** 420 mẫu (~12.2%)
- **Neutral (Trung tính):** 2,146 mẫu (~62.1%)

Nhận xét: Bộ dữ liệu Financial PhraseBank (cấu hình Sentences_75Agree) thể hiện rõ đặc trưng ngôn ngữ báo chí tài chính với sự mất cân bằng phân lớp sâu sắc, trong đó nhãn Trung tính (Neutral) chiếm tỷ lệ áp đảo 62.1%, bỏ xa nhãn Tích cực (25.7%) và Tiêu cực (12.2%). Sự chênh lệch này xuất phát từ bản chất tường thuật số liệu khách quan của các báo cáo doanh nghiệp, đồng thời các tin tức tiêu cực thường được trình bày cẩn trọng, nói

giảm nói tránh. Đặc thù này đặt ra thách thức lớn cho bài toán phân loại, buộc chúng em không chỉ giữ nguyên các con số, ký hiệu tài chính hay từ phủ định ở bước tiền xử lý, mà còn phải sử dụng thêm các độ đo như Precision, Recall, F1-score và Ma trận nhầm lẫn (Confusion Matrix) thay vì chỉ dùng Accuracy để đánh giá chính xác năng lực nhận diện của mô hình đối với các lớp thiểu số nhưng mang ý nghĩa quan trọng.

3.2. Tiền xử lý dữ liệu (Data Preprocessing)

Văn bản tài chính chứa nhiều con số và thuật ngữ đặc thù, do đó quy trình tiền xử lý được thiết kế để làm sạch nhiều nhưng vẫn giữ lại các đặc trưng quan trọng:

- Chuẩn hóa Unicode & Khúc chiết văn bản: Sử dụng chuẩn NFKC để đồng nhất các ký tự Unicode phức tạp và loại bỏ các khoảng trắng thừa, giúp văn bản đưa về định dạng gốc.
- Lọc ký tự (Dành riêng cho TF-IDF): Đưa toàn bộ chữ về chữ thường (lowercase). Đặc biệt, không xóa toàn bộ ký tự đặc biệt như cách tiền xử lý thông thường. Thay vào đó, bộ lọc chỉ giữ lại chữ cái, chữ số và các ký hiệu mang ý nghĩa tài chính cao như %, \$, €, £, ., +, -, ().
- Trích xuất đặc trưng bổ sung (Feature Extraction): Tạo thêm các cờ (flags) để nhận diện sự xuất hiện của các từ khóa nhạy cảm tác động đến cảm xúc, bao gồm:
 - + Sự xuất hiện của con số, tỷ lệ phần trăm (has_number, has_percent) và ký hiệu tiền tệ (has_currency).
 - + Đặc trưng từ phủ định (has_negation): Xây dựng tập từ điển phủ định (*no, not, never, without, hardly...*) để mô hình dễ dàng nhận diện các câu bị đảo ngược cực tính cảm xúc (Ví dụ: "*not increase*").

3.3. Biểu diễn dữ liệu (Data Representation)

Để thuật toán học máy có thể hiểu được văn bản, dữ liệu chữ sau khi tiền xử lý được chuyển đổi thành các vector số học thông qua hai hướng tiếp cận khác nhau:

Biểu diễn bằng TF-IDF kết hợp N-gram:

- Đối với các mô hình học máy truyền thống (Baseline Models), nhóm sử dụng phương pháp **TF-IDF (Term Frequency - Inverse Document Frequency)**. Phương pháp này đánh giá tầm quan trọng của một từ không chỉ dựa trên tần suất xuất hiện của nó trong câu, mà còn phạt (giảm trọng số) những từ xuất hiện quá phổ biến trong toàn bộ tập dữ liệu (như *the*, *and*, *is*).
- **Kết hợp N-gram:** Thay vì chỉ cắt từng từ đơn lẻ (Unigram - 1-gram), mô hình TF-IDF được kết hợp thêm N-gram (ví dụ: Bi-gram - cụm 2 từ liên tiếp). Việc này giúp bắt được các cụm từ đi liền nhau mang ý nghĩa tài chính hoặc phủ định (Ví dụ: thay vì tách rời "*net*" và "*loss*", n-gram giúp mô hình hiểu cụm "*net loss*" là một đặc trưng tiêu cực).

3.4. Xây dựng các mô hình

Để giải quyết bài toán phân loại cảm xúc, nhóm tiếp cận theo chiến lược từ đơn giản đến phức tạp: thiết lập một cột mốc cơ sở (baseline) để đối chiếu, sử dụng các thuật toán học máy truyền thống kết hợp TF-IDF, và cuối cùng tiến đến mô hình ngôn ngữ lớn chuyên sâu.

3.4.1. Dummy Classifier

- **Vai trò:** Được sử dụng làm cột mốc cơ sở thấp nhất (baseline) để kiểm chứng hiệu năng của các mô hình khác.
- **Cơ chế:** Trong đề tài này, Dummy Classifier được cấu hình dự đoán nhãn dựa trên tần suất lớp chiếm đa số (chiến lược *most_frequent*). Do dữ liệu mất cân bằng nặng (lớp Neutral chiếm hơn 62%), Dummy Classifier sẽ luôn dự đoán kết quả là Neutral cho mọi câu văn mà không cần học bất kỳ đặc trưng từ vựng nào.
- **Ý nghĩa:** Nếu một mô hình học máy phức tạp có độ chính xác (Accuracy) hoặc F1-score không vượt qua được Dummy Classifier, điều đó chứng tỏ mô hình học máy đó hoàn toàn thất bại trong việc trích xuất đặc trưng văn bản.

3.4.2. Naive Bayes (Multinomial Naive Bayes)

- **Cơ chế:** Là thuật toán dựa trên định lý Bayes với giả định "ngây thơ" (naive) rằng sự xuất hiện của các từ trong một câu là hoàn toàn độc lập với nhau. Biến thể *Multinomial* đặc biệt phù hợp để làm việc với dữ liệu đếm tần suất từ hoặc TF-IDF.
- **Đặc điểm:** Tốc độ huấn luyện cực kỳ nhanh và hoạt động khá ổn định với dữ liệu văn bản thưa thớt (sparse data). Dù giả định độc lập từ vựng thường không đúng trong thực tế, Naive Bayes vẫn là một baseline truyền thống không thể thiếu trong xử lý ngôn ngữ tự nhiên.

3.4.3. Logistic Regression

- **Cơ chế:** Khác với Naive Bayes (mô hình sinh học), Logistic Regression là mô hình phân biệt (Discriminative Model). Thuật toán tối ưu hóa một hàm mất mát để tìm ra ranh giới tuyến tính phân chia 3 lớp cảm xúc (Positive, Negative, Neutral).
- **Đặc điểm:** Hoạt động rất tốt với không gian đặc trưng nhiều chiều (như ma trận TF-IDF n-gram). Trọng số của mô hình này cũng mang tính diễn giải cao: ta có thể trích xuất được những từ vựng nào (features) có trọng số âm lớn (tác động tiêu cực) hay trọng số dương lớn (tác động tích cực) đến quyết định phân loại.

3.4.4. Linear SVM (Support Vector Machine)

- **Cơ chế:** Mục tiêu của SVM là tìm ra siêu phẳng (hyperplane) có khoảng cách lề (margin) lớn nhất phân tách giữa các lớp. Với văn bản, hạt nhân tuyến tính (Linear Kernel) được ưu tiên sử dụng thay vì RBF do số lượng chiều đặc trưng (từ vựng) đã rất lớn, thường lớn hơn số lượng mẫu.
- **Đặc điểm:** Linear SVM nổi tiếng là một trong những thuật toán học máy truyền thống mạnh mẽ nhất cho phân loại văn bản. Mô hình xử lý rất tốt các nhiễu từ vựng, có tính tổng quát hóa cao và thường là đối thủ đáng gờm nhất so với các mô hình học sâu cơ bản.

3.5. Đánh giá và kiểm định hệ thống

Trong quá trình xây dựng hệ thống phân tích cảm xúc tài chính, do bộ dữ liệu nền tảng có hiện tượng mất cân bằng phân lớp (tin tức Trung tính chiếm hơn 62%), nhóm không chỉ sử dụng Accuracy mà còn thiết lập một hệ thống tiêu chuẩn đánh giá đa chiều. Các kết quả chạy thực nghiệm trên tập kiểm thử (Test set) đã phản ánh rõ ý nghĩa của từng độ đo này:

3.5.1. Accuracy (Độ chính xác tổng thể)

Độ đo này thể hiện tỷ lệ câu văn được phân loại đúng trên toàn bộ tập dữ liệu. Kết quả thực nghiệm cho thấy, nếu chỉ dùng mô hình cơ sở Dummy Classifier (chiến lược luôn dự đoán là Neutral), Accuracy vẫn tự động đạt mức **62.16%**. Tuy nhiên, mô hình tốt nhất là Logistic Regression đã nâng mức Accuracy lên **85.71%**. Con số này chứng tỏ hệ thống thực sự học được các đặc trưng ngôn ngữ chứ không đoán mò. Dù vậy, do dữ liệu mất cân bằng, Accuracy chỉ được nhóm dùng làm thước đo kiểm tra nhanh chứ chưa đủ để đánh giá toàn diện.

3.5.2. Precision (Độ chuẩn xác)

Precision đo lường mức độ "chắc chắn" của hệ thống: trong số các câu bị cảnh báo là Tiêu cực (Negative), có bao nhiêu câu thực sự đúng. Điều này rất quan trọng để tránh báo động giả (False Positive) gây hoang mang cho nhà đầu tư. Kết quả thực nghiệm cho thấy Logistic Regression đạt Precision rất ấn tượng ở lớp Tiêu cực (**89.13%**). Điều này có nghĩa là một khi hệ thống đã phát tín hiệu cảnh báo rủi ro, độ tin cậy là cực kỳ cao.

3.5.3. Recall (Độ bao phủ)

Trái ngược với Precision, Recall đo lường khả năng "không bỏ sót" của hệ thống. Dựa trên kết quả chạy code, lớp Tiêu cực có chỉ số Recall khá khiêm tốn (chỉ đạt **65.08%**). Con số thực tế này phản ánh đúng thách thức cốt lõi của văn bản tài chính: các thông tin xấu thường được doanh nghiệp bọc lót bằng ngôn từ khéo léo, nói giảm nói tránh. Do đó, hệ thống (dựa trên TF-IDF) thỉnh thoảng vẫn bị "lừa" và bỏ sót các tín hiệu tiêu cực ẩn giấu này.

3.5.4. F1-score

F1-score là trung bình điều hòa giữa Precision và Recall. Nhóm đặc biệt sử dụng **Macro-F1** (F1 trung bình của cả 3 lớp) làm **thước đo quyết định**. Trong khi Dummy Classifier chỉ đạt Macro-F1 vồn vẹn **25.56%** (hoàn toàn bất lực trong việc phân biệt cảm xúc), thì mô hình Logistic Regression đạt mức **81.00%**. Điểm số này chứng minh hệ thống đã cân bằng rất tốt giữa việc bắt trúng sắc thái tài chính và hạn chế báo động nhầm.

3.5.5. Classification Report (Báo cáo phân loại chi tiết)

Bảng báo cáo này cung cấp cái nhìn "nội soi" cho từng phân lớp riêng biệt. Kết quả xuất ra từ hệ thống cho thấy một bức tranh rõ ràng: hệ thống xử lý lớp Neutral vô cùng xuất sắc (F1 đạt **91%**), xử lý lớp Positive khá tốt (F1 đạt **77%**), nhưng vẫn gặp khó khăn ở lớp Negative (F1 đạt **75%**). Việc bóc tách dữ liệu bằng Classification Report giúp nhóm nhận diện chính xác "nút thắt" năng lực của các thuật toán học máy truyền thống.

3.5.6. Confusion Matrix (Ma trận nhầm lẫn)

Ma trận nhầm lẫn được nhóm sử dụng cho mục tiêu phân tích lỗi (Error Analysis). Quan sát vùng phân bố trên ma trận thực tế của mô hình, phần lớn các lỗi sai đều tập trung ở việc hệ thống đẩy nhầm các câu mang cực tính nhẹ (Tích cực hoặc Tiêu cực) vào hộp Trung tính. Điểm mù này xuất phát từ việc mất ngữ cảnh của TF-IDF.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Môi trường và dữ liệu thực nghiệm

– Môi trường thực nghiệm:

Để đảm bảo tính nhất quán và khả năng chạy các mô hình học sâu, đề tài được triển khai trên cả hai môi trường linh hoạt:

- + **Môi trường cục bộ (Local):** Sử dụng Visual Studio Code với Python 3.12, phục vụ cho việc tiền xử lý dữ liệu, phân tích EDA và huấn luyện nhanh các mô hình học máy cơ bản (scikit-learn, pandas).


- + **Môi trường đám mây (Cloud):** Sử dụng Google Colab kết nối với GPU (CUDA) để tối ưu hóa tốc độ xử lý khi tải trọng số và chạy suy luận (inference) cho mô hình.
- + **Cấu hình tham số:** Quá trình chia dữ liệu (Train/Val/Test) và khởi tạo mô hình đều được thiết lập hạt giống ngẫu nhiên cố định (`random_seed = 42`) để đảm bảo kết quả thực nghiệm có thể tái lập chính xác trong nhiều lần chạy khác nhau.

– **Dữ liệu:**

Dữ liệu được đọc từ Financial PhraseBank, tập Sentences_75Agree.txt. Tập ban đầu có 3.453 câu hợp lệ. Sau khi chuẩn hóa và loại 5 câu trùng, tập còn 3.448 câu để chia train/validation/test.

Nhãn	Số lượng	Tỷ lệ
Negative	420	12,16%
Neutral	2.146	62,15%
Positive	887	25,69%
Tổng	3.453	100%

Bảng 4.1.1: Thống kê dữ liệu Financial PhraseBank




Hình 4.1.1. Phân bố nhãn trong dữ liệu ban đầu

Phân bố nhãn cho thấy Neutral chiếm ưu thế rõ rệt, lớn hơn tổng tỷ lệ của Negative và Positive. Vì vậy, một mô hình dự đoán thiên về Neutral có thể đạt Accuracy khá cao nhưng Macro-F1 thấp. Điều này giải thích vì sao Macro-F1 được chọn làm chỉ số chính.


Đặc trưng	Giá trị
Câu rỗng	0
Nhãn thiếu	0
Câu trùng sau chuẩn hóa	5
Câu còn lại sau loại trùng	3.448
Câu chứa số	57,72%
Câu chứa phần trăm	7,88%

Câu chứa ký hiệu tiền tệ	3,94%
Câu chứa từ phủ định	4,00%

Bảng 4.1.2: Thống kê tổng quan các đặc trưng của bộ dữ liệu sau tiền xử lý.



Hình 4.1.2. Phân bố độ dài câu



Hình 4.1.3. Độ dài câu theo nhãn

Hơn một nửa số câu chứa số, cho thấy con số là thành phần quan trọng trong ngôn ngữ tài chính. Tỷ lệ câu có phần trăm và đơn vị tiền tệ thấp hơn nhưng có ý nghĩa mạnh trong các câu mô tả tăng giảm, doanh thu, lợi nhuận hoặc chi phí. Từ phủ định xuất hiện khoảng 4,00%, tuy không nhiều nhưng có thể đảo chiều nghĩa của câu, vì vậy không được xóa trong tiền xử lý.

Tập	Số mẫu	Negative	Neutral	Positive
Train	2.412	294	1.497	621
Validation	518	63	322	133
Test	518	63	322	133
Tổng	3.448	420	2.141	887

Bảng 4.1.3: Thống kê chi tiết tỷ lệ chia tách dữ liệu và phân bố nhãn.

Tỷ lệ nhãn giữa train, validation và test gần như giống nhau nhờ stratified split. Kiểm tra giao nhau giữa train-validation, train-test và validation-test đều bằng 0, cho thấy bước loại trùng trước khi chia đã giảm nguy cơ data leakage.

Thành phần	Cấu hình
Random seed	42
Tỷ lệ chia	Train 70%, validation 15%, test 15%
Kiểu chia	Stratified theo nhãn
Vectorizer	TF-IDF
N-gram	Unigram và bigram
Metric lựa chọn	Validation Macro-F1
Mô hình test cuối	Linear SVM

Bảng 4.1.4: Bảng tổng hợp cấu hình kỹ thuật của hệ thống phân loại.

4.2. Kết quả của các mô hình

Trong giai đoạn này, các mô hình lần lượt được huấn luyện và đối chiếu qua các chỉ số Accuracy và Macro-F1. Các số liệu dưới đây phản ánh rõ nét ranh giới hiệu năng giữa các thuật toán:

4.2.1. Dummy Classifier

- **Kết quả:** Đạt Accuracy **62.16%** và Macro-F1 chỉ vón vện **25.56%**. Thời gian huấn luyện diễn ra tức thời (~0.17 giây).
- **Nhận xét:** Mô hình này chỉ đơn thuần "nhắm mắt" gán mọi câu văn vào nhãn Trung tính (Neutral) vì đây là lớp đông nhất trong tập huấn luyện. Sự chênh lệch khổng lồ

giữa Accuracy (khá cao) và Macro-F1 (đáy) là minh chứng rõ ràng nhất cho việc không thể dùng Accuracy để đánh giá dữ liệu tài chính mất cân bằng.

4.2.2. Naive Bayes

- **Kết quả:** Đạt Accuracy **83.59%** và Macro-F1 **74.58%**. Thời gian chạy cực kỳ nhanh (~3.1 giây).
- **Nhận xét:** Sử dụng biến thể Multinomial kết hợp TF-IDF, Naive Bayes đã thiết lập một bước tiến lớn so với Dummy. Dù có giả định "ngây thơ" về sự độc lập của các từ vựng, mô hình vẫn nhận diện khá tốt các câu có chứa từ khóa bộc lộ cảm xúc rõ ràng. Tuy nhiên, nó bắt đầu gặp lỗi ở những câu phức tạp có chứa từ phủ định (do tính độc lập từ vựng).

4.2.3. Logistic Regression

- **Kết quả:** Đạt Accuracy **85.71%** và Macro-F1 **81.00%** (trên tập Test). Thời gian huấn luyện khoảng ~3.8 giây.
- **Nhận xét:** Đây là mô hình mang lại **hiệu năng tổng thể tốt nhất** trong nhóm học máy truyền thống (Baselines). Nhờ khả năng tối ưu hóa ranh giới quyết định trên không gian vector TF-IDF, Logistic Regression xử lý cực tốt lớp Neutral (F1 đạt 91%) và Positive (F1 đạt 77%). Dù vậy, nó vẫn gặp "nút thắt" ở lớp Negative (F1 75%) do hiện tượng nói giảm nói tránh trong văn bản gốc khiến các từ khóa tiêu cực bị lu mờ.

4.2.4. Linear SVM

- **Kết quả:** Đạt Accuracy **86.68%** và Macro-F1 **80.21%** (trên tập Validation). Thời gian chạy rất tối ưu (~1.7 giây).
- **Nhận xét:** Là đối thủ đáng gờm của Logistic Regression, Linear SVM tạo ra một siêu phẳng phân cách cực kỳ mạnh mẽ trên không gian đặc trưng văn bản dày đặc. Mô hình này vượt trội nhẹ về Accuracy nhưng lại thua một chút xíu ở Macro-F1. Nhìn chung, Linear SVM và Logistic Regression phản ánh mức "trần" (upper

bound) tối đa mà các phương pháp đếm từ (Bag-of-Words/TF-IDF) có thể đạt tới khi không hiểu được ngữ cảnh sâu xa của câu.

4.3. So sánh kết quả giữa các mô hình

Tổng hợp từ các số liệu thực nghiệm, ta có thể rút ra một bức tranh toàn cảnh về năng lực của các thuật toán khi đối mặt với ngôn ngữ tài chính:

- **Hạn chế của phương pháp truyền thống:** Các mô hình đếm từ vừng (Bag-of-words/TF-IDF) như Naive Bayes, Linear SVM và Logistic Regression có ưu điểm tuyệt đối về tốc độ huấn luyện (dưới 4 giây) và dễ dàng triển khai. Dù Logistic Regression đạt Macro-F1 rất tốt (81%), nhưng điểm yếu chí mạng của toàn bộ nhóm này là **sự vô cảm với ngữ cảnh**. Nếu một câu xuất hiện từ "loss", TF-IDF lập tức cộng điểm Tiêu cực, bất chấp việc câu đó có thể là *"We successfully reduced our net loss"* (Một tín hiệu Tích cực).

- Đánh giá tổng quát:

Mô hình	Accuracy	Macro Precision	Macro Recall	Macro-F1	Weighted-F1	Thời gian huấn luyện (giây)
Logistic Regression	0,8629	0,8295	0,7873	0,8058	0,8600	1,9048
Linear SVM	0,8668	0,8347	0,7779	0,8021	0,8622	0,3198
Naive Bayes	0,8359	0,7960	0,7150	0,7458	0,8252	3,1762
Dummy	0,6216	0,2072	0,3333	0,2556	0,4766	0,0778

Bảng 4.3.1: So sánh tổng quát trên tập VALIDATION



Nhận xét:

- **Dummy Classifier** hiển thị mức sàn của hệ thống với Macro-F1 cực thấp (25.56%), chứng tỏ việc "đoán mò" hoàn toàn vô tác dụng trong bài toán này.
 - Cả **Logistic Regression** và **Linear SVM** đều thể hiện sự vượt trội, bám đuổi nhau rất sát sao. Trong khi Linear SVM nhỉnh hơn một chút về Accuracy (86.68%), thì Logistic Regression lại giành chiến thắng ở chỉ số quan trọng nhất là Macro-F1 (80.58%), cho thấy sự cân bằng tốt hơn trong việc nhận diện đa lớp cảm xúc.
 - **Naive Bayes** dù có tốc độ nhanh nhưng chịu mức F1 tụt hậu rõ rệt (74.58%) do hạn chế trong việc nhận diện tổ hợp từ phủ định.
- Đánh giá chi tiết trên từng lớp:


Mô hình	Nhãn	Precision	Recall	F1	Số mẫu
Dummy	negative	0,0000	0,0000	0,0000	63
Dummy	neutral	0,6216	1,0000	0,7667	322
Dummy	positive	0,0000	0,0000	0,0000	133
Naive Bayes	negative	0,7234	0,5397	0,6182	63
Naive Bayes	neutral	0,8587	0,9814	0,9159	322
Naive Bayes	positive	0,8058	0,6241	0,7034	133

Logistic Regression	negative	0,7885	0,6508	0,7130	63
Logistic Regression	neutral	0,8968	0,9441	0,9198	322
Logistic Regression	positive	0,8031	0,7669	0,7846	133
Linear SVM	negative	0,7800	0,6190	0,6903	63
Linear SVM	neutral	0,8908	0,9627	0,9254	322
Linear SVM	positive	0,8333	0,7519	0,7905	133

Bảng 4.3.2: chi tiết theo từng lớp (negative / neutral / positive) trên VALIDATION



Hình 4.3.1: Trục quan hóa chỉ số Macro-F1 và Accuracy giữa các mô hình trên tập Validation.



Hình 4.3.2: Trục quan hóa chi tiết hiệu năng nhận diện từng phân lớp (Negative, Neutral, Positive) của các mô hình cơ sở.

Nhận xét:

- **Lớp Trung tính (Neutral):** Tất cả các mô hình đều nhận diện xuất sắc lớp đa số này với F1-score xoay quanh mức >91%, riêng Linear SVM làm tốt nhất (92.54%).
- **Lớp Tích cực (Positive):** Linear SVM nhỉnh hơn ở độ chuẩn xác (Precision 83.33%), kéo theo F1-score (79.05%) nhỉnh hơn Logistic Regression một chút.
- **Lớp Tiêu cực (Negative):** Đây chính là điểm thất cổ chai quyết định sự thắng bại. Lớp Negative là lớp thiểu số và khó phân loại nhất do ngôn từ nói giảm nói tránh. Tại đây, **Logistic Regression** thể hiện khả năng "bắt bệnh" tốt hơn hẳn với Recall đạt **65.08%** (bỏ sót ít tín hiệu tiêu cực hơn) so với mức 61.90% của Linear SVM. Từ đó, F1-score lớp Tiêu cực của Logistic Regression đạt **71.30%**, bỏ xa SVM (69.03%) và Naive Bayes (61.82%).
- **Kết luận lựa chọn mô hình:**

Thông qua các kết quả thực nghiệm trên tập Xác thực, mặc dù Linear SVM mang lại Độ chính xác (Accuracy) tổng thể cao nhất, nhưng Logistic Regression (với tham số tốt nhất $C=10.0$) lại chứng minh được sự toàn diện và cân bằng đáng giá hơn thông qua chỉ số Macro-F1 cao nhất (80.58%).

Khả năng bắt sóng các tín hiệu Tiêu cực (Negative) nhạy bén của Logistic Regression là đặc tính cốt lõi mà một hệ thống tài chính luôn tìm kiếm. Do đó, đề tài đưa ra quyết định chọn Logistic Regression làm mô hình cơ sở (Baseline) tốt nhất để tiến hành chạy đánh giá và kết luận cuối cùng trên tập Kiểm thử (Test set).

4.4 Đánh giá trên tập Kiểm thử (Test Evaluation)

Từ kết quả tối ưu và so sánh ở chương trước, mô hình **Logistic Regression (với tham số $C=10.0$)** đã được chọn làm đại diện xuất sắc nhất của nhóm học máy truyền thống. Trong chương này, mô hình sẽ được đem ra thử lửa lần cuối cùng trên tập Kiểm thử (Test set) – tập dữ liệu mà mô hình hoàn toàn chưa từng được nhìn thấy trong suốt quá trình huấn luyện và tinh chỉnh. Mục tiêu là để đo lường năng lực thực tiễn khách quan nhất của hệ thống.

Mô hình	Accuracy	Macro Precision	Macro Recall	Macro-F1	Weighted-F1	Mô hình
Logistic Regression	0,8571	0,8487	0,7842	0,81	0,8545	Logistic Regression

Bảng 4.4.1: Kết quả TEST cho mô hình tốt nhất (Logistic Regression)

- Bảng báo cáo phân loại (Classification Report):

Kết quả dự đoán trên 518 câu văn của tập Test cho thấy hệ thống hoạt động vô cùng ổn định, giữ vững phong độ tương đương như trên tập Xác thực với **Accuracy đạt 85.71%** và **Macro-F1 đạt 81.00%**. Chi tiết từng phân lớp được thể hiện qua bảng sau:

Mô hình	Nhãn	Precision	Recall	F1	Số mẫu
Logistic Regression	negative	0,8913	0,6508	0,7523	63
Logistic Regression	neutral	0,8879	0,9348	0,9107	322
Logistic Regression	positive	0,7669	0,7669	0,7669	133


Bảng 4.4.2: Chi tiết theo từng lớp trên TEST(Logistic Regression)

Nhận xét :


- Mô hình có khả năng phân biệt lớp Trung tính xuất sắc ($F1 > 91\%$).
- Điểm nổi bật nhất là **Precision của lớp Tiêu cực lên tới 89.13%**. Mặc dù đây là lớp có số lượng mẫu ít nhất (63 mẫu), nhưng hệ thống đã học được các đặc trưng từ vựng cốt lõi. Một khi hệ thống dán nhãn "Tiêu cực", tỷ lệ đúng là rất cao, giúp hạn chế rủi ro báo động giả (False Positives).

- Phân tích Ma trận nhầm lẫn (Confusion Matrix):

Để bóc tách sâu hơn các điểm mù của hệ thống (lý do tại sao Recall của lớp Negative chỉ đạt 65.08%), đề tài tiến hành phân tích thông qua Ma trận nhầm lẫn dưới hai dạng: Số lượng tuyệt đối và Tỷ lệ chuẩn hóa theo hàng (Recall Matrix).



Hình 4.4.1: Confusion Matrix theo số lượng – Logistic Regression



Hình 4.4.2: Confusion Matrix theo tỷ lệ hàng – Logistic Regression

- **Nhận xét và Phân tích lỗi (Error Analysis) từ ma trận:**
 - **Khả năng nhận diện lớp thiểu số (Tiêu cực & Tích cực):** Dựa vào ma trận chuẩn hóa, ta có thể thấy hệ thống nhận diện đúng 76.69% các câu Tích cực thực tế và 65.08% các câu Tiêu cực thực tế. Mặc dù dữ liệu bị mất cân bằng trầm trọng (thiên lệch về Neutral), việc thiết lập tham số `class_weight='balanced'` đã phát huy tác dụng rõ rệt, ép hệ thống phải chú ý đến các mẫu thiểu số này.
 - **Phân tích nguyên nhân nhầm lẫn chính:** Quan sát trên ma trận, sự nhầm lẫn giữa Tích cực và Tiêu cực là **rất hiếm khi xảy ra**. Gần như không có trường hợp nào mô hình nhầm một tin quá tốt thành tin quá xấu. Thay vào đó, **hầu hết các lỗi sai đều nằm ở việc hệ thống hút các mẫu cực tính (Negative/Positive) về lớp**

Neutral. (Khoảng 35% số câu Tiêu cực và 23% số câu Tích cực bị hệ thống dán nhãn nhầm thành Trung tính).

- **Giới hạn của TF-IDF và Tiền đề cho học sâu:** Lỗi phân loại sai này không phải do mô hình Logistic Regression kém, mà là do giới hạn vật lý của phương pháp đếm từ (TF-IDF). Trong văn bản tài chính, các thông tin xấu đôi khi không chứa các từ khóa tiêu cực mạnh (như *loss*, *bad*, *decline*) mà được bọc lót trong các cụm câu tường thuật dài dòng mang tính chất nói giảm nói tránh. TF-IDF chỉ đếm từ vựng độc lập, không bắt được ngữ cảnh hai chiều của toàn câu, dẫn đến việc bị thiếu "bằng chứng" để ra quyết định và phải ngậm ngùi xếp câu đó vào nhóm Trung tính an toàn..

4.5. Phân tích lỗi (Error Analysis)

Để tối ưu hóa hệ thống trong tương lai, việc thấu hiểu "tại sao mô hình đoán sai" quan trọng không kém việc biết nó đoán đúng bao nhiêu phần trăm. Đề tài đã tiến hành cô lập 71 mẫu dự đoán sai trên tập Test (chiếm khoảng 14%) để thực hiện phân tích chuyên sâu.

4.5.1. Các cặp nhầm lẫn phổ biến nhất

Bảng dưới đây thống kê các kiểu nhầm lẫn (từ nhãn thực tế sang nhãn dự đoán) có tần suất xuất hiện cao nhất:

Nhãn thực tế (True Label)	Nhãn dự đoán sai (Predicted)	Số lượng lỗi
Positive (Tích cực)	Neutral (Trung tính)	28
Neutral (Trung tính)	Positive (Tích cực)	19
Negative (Tiêu cực)	Positive (Tích cực)	12

Negative (Tiêu cực)	Neutral (Trung tính)	10
----------------------------	-----------------------------	----

Bảng 4.5.1: Thống kê các kiểu nhầm lẫn xuất hiện nhiều nhất

Nhận xét: Kiểu lỗi phổ biến nhất (28 câu) là hệ thống đánh giá các tín hiệu Tích cực thành Trung lập. Điều này cho thấy với phương pháp TF-IDF, hệ thống thỉnh thoảng tỏ ra "bảo thủ", thiếu tự tin để phát tín hiệu Tích cực nếu câu văn không chứa các từ khóa tăng trưởng quá mạnh. Ngoài ra, việc nhầm lẫn từ Tiêu cực sang Tích cực (12 câu) là một cảnh báo đỏ, đòi hỏi hệ thống cần được nâng cấp về khả năng đọc hiểu ngữ cảnh.

4.5.2. Lỗi theo đặc trưng ngôn ngữ

Đề tài so sánh tỷ lệ dự đoán sai giữa các câu bình thường và các câu có chứa đặc trưng khó (phủ định, số liệu):

- **Từ phủ định (Negation):** Tỷ lệ lỗi ở các câu chứa từ phủ định chỉ ở mức **5.00%**, thấp hơn rất nhiều so với mức 14.66% của các câu thông thường. Điều này chứng minh bước thêm cờ has_negation ở phần Tiền xử lý đã phát huy tác dụng xuất sắc.
- **Số liệu (Number) & Phần trăm (%):** Tỷ lệ lỗi lần lượt là **14.29%** và **13.79%**, gần như không có sự khác biệt so với các câu không chứa số liệu (~14.3%).
- **Ký hiệu tiền tệ (Currency):** Tỷ lệ lỗi vọt lên cao nhất, đạt **25.00%** (so với 13.94% ở câu không chứa tiền tệ). Nguyên nhân do các câu có chứa tiền tệ thường đi kèm cấu trúc ngữ pháp phức tạp (so sánh doanh thu, bù trừ chi phí) khiến hệ thống bị nhiễu.

4.5.3. Lỗi theo độ dài câu

Bảng phân phối dưới đây kiểm chứng xem độ dài của câu văn có làm giảm trí thông minh của hệ thống hay không:

Nhóm độ dài câu	Tỷ lệ dự đoán đúng	Tỷ lệ dự đoán sai (Error Rate)	Nhận xét
<= 10 từ	90,91%	9,09%	Xử lý tốt nhất.
11 - 20 từ	89,42%	10,58%	Hoạt động rất ổn định.
21 - 30 từ	81,36%	18,64%	Tỷ lệ lỗi tăng vọt cao nhất.
> 30 từ	83,15%	16,85%	Hệ thống gặp nhiều khó khăn.

Bảng 4.5.3: Phân phối tỷ lệ nhầm lẫn

4.6. Ứng dụng thực tiễn: Đánh giá cảm xúc trên Báo cáo thường niên

Để chứng minh giá trị thực tiễn của đề tài, hệ thống không chỉ dừng lại ở các con số đánh giá trên tập kiểm thử (Test set) mà được tích hợp thành một module ứng dụng tự động. Module này sử dụng mô hình học máy tốt nhất (Logistic Regression) để đọc hiểu và đo lường "nhiệt kế cảm xúc" trực tiếp từ Báo cáo thường niên (Annual Report) định dạng PDF của doanh nghiệp.

4.6.1. Quy trình xử lý tự động

Việc chuyển đổi từ một file PDF tĩnh sang các báo cáo cảm xúc được thực hiện qua một luồng dữ liệu khép kín:

1. **Trích xuất và làm sạch (PDF to Text):** Hệ thống sử dụng thư viện chuyên dụng (PyMuPDF / pdfplumber) để quét toàn bộ văn bản. Mọi ký tự nhiễu như tiêu đề

trang (headers), ngắt dòng gương ép đều được thuật toán tự động dọn dẹp để khôi phục lại các đoạn văn hoàn chỉnh.

2. **Tách câu (Sentence Tokenization):** Văn bản thô được hệ thống chẻ nhỏ thành một danh sách hàng trăm câu độc lập.
3. **Suy luận (Inference):** Danh sách các câu này được đẩy qua mô hình Logistic Regression. Hệ thống tự động chấm điểm và gán nhãn (Negative, Neutral, Positive) cho từng câu.

4.6.2. Phân tích kết quả trên PDF

Nhận định nhanh sắc thái chung của báo cáo: Dựa vào biểu đồ phân bố, ta có thể rút ra nhận định nhanh về sức khỏe tài chính của doanh nghiệp trong kỳ báo cáo:


- Trọng tâm của tài liệu vẫn xoay quanh việc tường thuật số liệu khách quan, minh chứng qua việc nhãn **Trung tính (Neutral)** chiếm tỷ lệ áp đảo (thường >60%).
- Tuy nhiên, khi so sánh cực tính hai mảng còn lại, tỷ lệ câu mang nhãn **Tích cực (Positive)** lấn át rõ rệt so với nhóm **Tiêu cực (Negative)**. Điều này phát đi một tín hiệu định tính rất rõ ràng: Ban lãnh đạo doanh nghiệp đang truyền tải một thông điệp lạc quan về sự tăng trưởng, mở rộng thị phần hoặc cải thiện biên lợi nhuận trong năm qua. Rất ít các từ khóa liên quan đến rủi ro sụt giảm hay cắt giảm chi phí được hệ thống cảnh báo. Hệ thống ứng dụng này giúp các nhà phân tích rút ngắn thời gian đọc tài liệu từ vài giờ xuống chỉ còn vài giây.

4.7. Đóng gói Mô hình và Triển khai Sản phẩm phần mềm trên môi trường Web

4.7.1. Kiến trúc hệ thống (System Architecture)

Hệ thống được thiết kế theo kiến trúc phân lớp ở mức đơn giản, phù hợp với quy mô của một sản phẩm học máy phục vụ học tập và minh họa. Lớp giao diện sử dụng Streamlit để tiếp nhận thao tác của người dùng; lớp xử lý ứng dụng thực hiện kiểm tra đầu vào, trích xuất văn bản và tổ chức dữ liệu; lớp mô hình đảm nhiệm biến đổi TF-IDF và phân loại

cảm xúc; lớp triển khai chịu trách nhiệm lưu trữ mã nguồn, cài đặt thư viện và cung cấp dịch vụ Web. Các thành phần được tách theo chức năng nhằm giảm sự phụ thuộc giữa giao diện và logic suy luận.



Hình 4.7.1. Kiến trúc tổng thể của hệ thống phân tích cảm xúc tài chính

Sơ đồ trên thể hiện hai nhánh dữ liệu đầu vào chính. Với câu tài chính, nội dung được kiểm tra và chuyển trực tiếp đến pipeline. Với tài liệu PDF, hệ thống ưu tiên PyMuPDF để trích xuất văn bản và sử dụng pdfplumber làm phương án dự phòng; văn bản sau đó được chuẩn hóa và chia thành các câu hợp lệ. Cả hai nhánh cùng sử dụng pipeline TF-IDF kết hợp Logistic Regression được lưu trong tệp Joblib. Kết quả dự đoán được tổng hợp bằng Pandas và trình bày dưới dạng nhãn, xác suất, bảng, biểu đồ hoặc tệp CSV. Tệp metadata cung cấp thông tin cấu hình và chỉ số đánh giá, trong khi Groq API chỉ hỗ trợ diễn giải kết quả. GitHub và Streamlit Community Cloud tạo thành chuỗi quản lý mã nguồn và triển khai ứng dụng.

Tập/thành phần	Vai trò	Ý nghĩa khi triển khai

app.py	Khởi tạo trang Streamlit, tải mô hình, tổ chức các tab và hiển thị kết quả.	Là tệp vào chính khi Streamlit Community Cloud khởi chạy ứng dụng.
model_utils.py	Chứa các hàm chuẩn hóa nhãn, dự đoán câu, tách câu, trích xuất PDF và tổng hợp DataFrame.	Tách logic xử lý khỏi giao diện, giúp mã nguồn dễ kiểm tra và bảo trì.
models/financial_sentiment_pipeline.joblib	Lưu pipeline TF-IDF và Logistic Regression đã được huấn luyện.	Cho phép suy luận trực tiếp, không huấn luyện lại khi người dùng truy cập.
models/model_metadata.json	Lưu tên mô hình, nhãn, cấu hình dữ liệu và các chỉ số đánh giá.	Cung cấp dữ liệu cho trang “Thông tin mô hình” và hỗ trợ truy vết phiên bản.
requirements.txt	Khai báo Streamlit, scikit-learn, Pandas, Joblib, PyMuPDF, pdfplumber và Groq.	Cho phép môi trường đám mây cài đặt đúng các thư viện cần thiết.

Bảng 4.7.1 Vai trò của các tệp chính trong sản phẩm

Khi ứng dụng được khởi động, hàm tải mô hình đọc tệp Joblib và lưu đối tượng pipeline trong bộ nhớ đệm bằng `st.cache_resource`. Cơ chế này tránh việc tải lại mô hình ở mỗi lần Streamlit chạy lại giao diện, từ đó giảm thời gian phản hồi và mức sử dụng tài nguyên. Metadata được đọc riêng bằng bộ nhớ đệm dữ liệu để phục vụ trang thông tin mô hình. Trong quá trình suy luận, Logistic Regression cung cấp xác suất qua `predict_proba`; xác suất cao nhất được sử dụng làm mức độ tin cậy của nhãn dự đoán.

Về triển khai, mã nguồn được quản lý trên nhánh main của GitHub. Streamlit Community Cloud được cấu hình để sử dụng `app.py` làm tệp khởi chạy và `requirements.txt` làm cơ sở cài đặt môi trường. Khi một commit mới được đẩy lên GitHub, nền tảng có thể xây dựng và triển khai lại ứng dụng. Kiến trúc này có ưu điểm là đơn giản, dễ tái tạo và phù hợp với khối lượng suy luận của mô hình học máy cỡ nhỏ.

4.7.2. Giao diện và Luồng người dùng (User Flow)

Giao diện được tổ chức thành ba nhóm chức năng: dự đoán một câu, phân tích PDF và hiển thị thông tin mô hình. Ngoài khu vực nội dung chính, thanh bên cung cấp chức năng hỏi đáp và diễn giải kết quả bằng mô hình ngôn ngữ. Cách bố trí này giúp phân tách rõ thao tác suy luận, xử lý tài liệu và kiểm tra thông tin kỹ thuật của mô hình.



Hình 4.8.2 Giao diện tổng quan của ứng dụng Web Financial Sentiment Analysis

a) Luồng dự đoán cảm xúc đối với một câu tài chính

Bước 1. Nhập dữ liệu: Người dùng chọn một câu ví dụ hoặc nhập câu tiếng Anh thuộc lĩnh vực tài chính vào ô văn bản.

Bước 2. Gửi yêu cầu: Người dùng nhấn nút “Phân tích câu”; ứng dụng kiểm tra trường hợp dữ liệu rỗng trước khi thực hiện suy luận.

Bước 3. Biểu diễn và phân loại: Câu được đưa vào pipeline; TF-IDF biến đổi văn bản thành véc-tơ đặc trưng và Logistic Regression dự đoán một trong ba nhãn Negative, Neutral hoặc Positive.

Bước 4. Trả kết quả: Hệ thống hiển thị nhãn bằng tiếng Việt, đồng thời trình bày xác suất của từng lớp và đánh dấu lớp có xác suất cao nhất.

Bước 5. Diễn giải bổ sung: Khi Groq API được cấu hình, người dùng có thể nhập câu trong thanh bên để nhận phần giải thích bằng tiếng Việt. Thành phần này chỉ giải thích kết quả, không thay đổi nhãn của mô hình chính.

b) Luồng phân tích tài liệu PDF

Bước 1. Tải và kiểm tra tài liệu: Người dùng chọn tệp PDF có lớp văn bản; ứng dụng tiếp nhận dữ liệu và kiểm tra khả năng đọc nội dung.

Bước 2. Trích xuất và tách câu: Hệ thống ưu tiên PyMuPDF, dùng pdfplumber làm phương án dự phòng, sau đó chuẩn hóa khoảng trắng và lọc các câu theo độ dài.

Bước 3. Suy luận và tổng hợp: Danh sách câu được dự đoán theo lô; ứng dụng tính nhãn, xác suất, số lượng và tỷ lệ của ba nhóm cảm xúc.

Bước 4. Trình bày và xuất kết quả: Kết quả được hiển thị bằng bảng và biểu đồ; người dùng có thể tải tệp CSV để tiếp tục phân tích hoặc lưu trữ.

Trang “Thông tin mô hình” trình bày các chỉ số chính để người dùng nhận biết năng lực của mô hình và cấu hình đang được sử dụng. Theo kết quả thực nghiệm, Logistic Regression đạt Validation Macro-F1 bằng 0,8058; trên tập kiểm thử, Accuracy đạt 0,8571, Macro-F1 đạt 0,8100, Macro Precision đạt 0,8487, Macro Recall đạt 0,7842 và Weighted-F1 đạt 0,8545. Việc hiển thị đồng thời nhiều thước đo giúp tránh đánh giá mô hình chỉ dựa trên Accuracy trong bối cảnh phân bố nhãn không cân bằng.

Chỉ số	Giá trị	Ý nghĩa
--------	---------	---------

Validation Macro-F1	0,8058	Trung bình F1 của ba lớp trên tập validation; được dùng để lựa chọn mô hình.
Test Accuracy	0,8571	Tỷ lệ tổng số câu được dự đoán đúng trên tập test.
Test Macro-F1	0,8100	Trung bình F1 không trọng số giữa ba lớp, coi các lớp có vai trò ngang nhau.
Test Macro Precision	0,8487	Trung bình precision của các lớp; phản ánh mức hạn chế dự đoán dương tính sai theo từng lớp.
Test Macro Recall	0,7842	Trung bình recall của các lớp; phản ánh khả năng phát hiện đúng mẫu thuộc từng lớp.
Test Weighted-F1	0,8545	Trung bình F1 có trọng số theo số mẫu của mỗi lớp, chịu ảnh hưởng nhiều hơn từ lớp phổ biến.

Bảng 4.7.2 Các chỉ số đánh giá được hiển thị trong ứng dụng

Các kết quả trên chỉ phản ánh sắc thái ngôn ngữ trong câu hoặc tài liệu và không phải là khuyến nghị đầu tư, dự báo giá chứng khoán hoặc đánh giá toàn diện sức khỏe tài chính của doanh nghiệp. Đây là điều kiện sử dụng quan trọng cần được duy trì trên giao diện để hạn chế diễn giải sai mục đích của hệ thống.

4.7.3. Hạn chế và Hướng phát triển của Sản phẩm

Sản phẩm đã hoàn thành các chức năng cốt lõi gồm dự đoán câu tài chính, phân tích PDF, hiển thị xác suất, tổng hợp bảng và biểu đồ, xuất CSV, cung cấp thông tin mô hình và hỗ trợ diễn giải. Trong phạm vi đề tài, ứng dụng vận hành ổn định và minh họa được quy trình đưa mô hình NLP từ notebook lên Web; tuy nhiên, kết quả không phải độ chính xác tuyệt đối và không thay thế phân tích tài chính chuyên sâu.

a) Hạn chế hiện tại

TF-IDF dựa chủ yếu trên tần suất và sự xuất hiện của từ hoặc n-gram, nên chưa mô hình hóa đầy đủ trật tự dài hạn, quan hệ ngữ nghĩa và ngữ cảnh của toàn câu.

Mô hình có thể gặp khó khăn với phủ định phức tạp, câu chứa hàm ý, nội dung vừa tích cực vừa tiêu cực hoặc thông tin phụ thuộc vào đoạn trước.

Dữ liệu huấn luyện chủ yếu là câu tiếng Anh tài chính với quy mô giới hạn và phân bố lớp chưa hoàn toàn cân bằng; khả năng tổng quát hóa sang nguồn mới cần được đánh giá thêm bằng Macro-F1 và kết quả theo từng lớp.

Chất lượng phân tích PDF phụ thuộc vào văn bản trích xuất. PDF ảnh quét, tài liệu nhiều cột hoặc bảng biểu phức tạp có thể tạo câu sai hoặc thiếu nội dung; phiên bản hiện tại chưa tích hợp OCR.

Streamlit Community Cloud và Groq phụ thuộc vào tài nguyên, kết nối mạng và dịch vụ bên ngoài. Đồng thời, file Joblib, notebook, mã nguồn và metadata phải được duy trì trong cùng một phiên bản để tránh sai lệch giữa mô hình suy luận và thông tin hiển thị.

b) Hướng phát triển

Hướng phát triển trước hết là mở rộng và cân bằng dữ liệu bằng câu trích từ báo cáo thường niên, công bố doanh nghiệp và tin tức tài chính; đồng thời xây dựng tập kiểm thử ngoài miền dữ liệu ban đầu và bộ dữ liệu tiếng Việt được gán nhãn chuyên biệt. Về mô hình, có thể thử nghiệm FinBERT hoặc Transformer tài chính để cải thiện khả năng hiểu

phủ định, câu dài và từ đa nghĩa. Do yêu cầu tài nguyên lớn hơn, các mô hình này cần được so sánh có kiểm soát với Logistic Regression, Linear SVM và các baseline khác trên cùng cách chia dữ liệu và thước đo Macro-F1.

Về sản phẩm, hệ thống nên bổ sung OCR, xử lý bố cục nhiều cột, lưu thông tin trang và câu gốc, đồng thời phát triển API bằng FastAPI, cơ sở dữ liệu, tài khoản và lịch sử phân tích. Quản lý phiên bản, ghi nhật ký suy luận và đánh giá lại mô hình định kỳ sẽ tăng khả năng truy vết.

CHƯƠNG 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1. Kết luận

Đề tài "Phân tích cảm xúc văn bản tài chính và ứng dụng trên báo cáo thường niên của doanh nghiệp" đã hoàn thành trọn vẹn các mục tiêu đề ra ban đầu, đi từ quá trình nghiên cứu lý thuyết đến việc đóng gói thành công một sản phẩm phần mềm thực tiễn. Những thành quả nổi bật nhất của đề tài bao gồm:

- **Làm chủ quy trình Xử lý ngôn ngữ tự nhiên (NLP):** Đề tài đã xây dựng thành công một pipeline hoàn chỉnh từ bước thu thập dữ liệu (Financial PhraseBank), xử lý nhiều ngữ pháp, chuẩn hóa các đặc trưng chuyên ngành (từ phủ định, tiền tệ, số liệu), cho đến việc thiết lập ma trận biểu diễn từ vựng TF-IDF n-gram.
- **Xây dựng và tối ưu hóa hệ thống học máy:** Thông qua thực nghiệm nghiêm ngặt với kỹ thuật dò nghiệm GridSearchCV, nhóm đã chứng minh được **Logistic Regression (cùng cơ chế cân bằng trọng số class_weight='balanced')** là thuật toán hoạt động hiệu quả nhất. Mô hình này đã khắc phục phần lớn hiện tượng mất cân bằng dữ liệu của miền tài chính, đem lại chỉ số Macro-F1 đạt 81% trên tập kiểm thử.
- **Triển khai ứng dụng thực tiễn:** Khác với các nghiên cứu chỉ dừng lại ở chỉ số mô hình, đề tài đã phát triển thành công module đọc hiểu tài liệu PDF tự động và **triển khai (deploy) lên môi trường Web**. Ứng dụng này cho phép người dùng

cuối tương tác trực tiếp, tự động hóa hoàn toàn quy trình rút trích và tổng hợp "nhiệt kế cảm xúc" từ hàng trăm trang báo cáo của doanh nghiệp chỉ trong vài giây.

5.2. Hạn chế của đề tài

Bên cạnh những kết quả tích cực, trong quá trình triển khai, nhóm cũng nhận diện được một số hạn chế nhất định liên quan đến thuật toán và dữ liệu:

- **Giới hạn của thuật toán đếm từ (TF-IDF):** Dù Logistic Regression đã được tinh chỉnh tối ưu, nhưng bản chất phương pháp biểu diễn TF-IDF chỉ đếm tần suất xuất hiện của từ vựng mà bỏ qua thứ tự và cấu trúc ngữ pháp cục bộ. Do đó, qua quá trình phân tích lỗi (Error Analysis), hệ thống thỉnh thoảng vẫn bị "bối rối" trước các câu văn quá dài, chứa nhiều mệnh đề đan xen hoặc sử dụng lối nói giảm nói tránh.
- **Độ phủ của dữ liệu:** Tập dữ liệu Financial PhraseBank (~4,800 câu) dù chất lượng cao nhưng chủ yếu tập trung vào thị trường châu Âu (Đại học Aalto). Các từ vựng lóng của Phố Wall, các thuật ngữ chứng khoán thị trường Châu Á hoặc các văn cảnh đa nghĩa phức tạp hơn có thể chưa được bao phủ toàn diện.

5.3. Hướng phát triển

Dựa trên những hạn chế đã phân tích, nhóm đề xuất các hướng phát triển tiếp theo để nâng cấp hệ thống trở thành một công cụ phân tích tài chính chuyên nghiệp:

- **Nâng cấp lên kiến trúc Học sâu (Deep Learning):** Để giải quyết triệt để lỗi mất ngữ cảnh của các câu phức tạp, hướng đi quan trọng nhất trong tương lai là tích hợp các mô hình ngôn ngữ lớn dựa trên kiến trúc Transformer (như BERT hoặc FinBERT). Cơ chế đọc hiểu hai chiều (Bi-directional) của mạng Neural sẽ giúp hệ thống hiểu chính xác các câu bị đảo ngữ hoặc mang hàm ý sâu xa.

- **Phân tích cảm xúc đa phương thức (Live-stream Sentiment):** Nâng cấp hệ thống Web không chỉ đọc file PDF báo cáo tĩnh, mà còn kết nối API để thu thập (crawling) và phân tích cảm xúc các tin tức chứng khoán, dòng trạng thái trên mạng xã hội theo thời gian thực (Real-time).
- **Thử nghiệm với Dữ liệu tiếng Việt:** Từ bộ khung pipeline đã hoàn thiện hiện tại, hướng đi tiềm năng tiếp theo là tự thu thập dữ liệu báo cáo tài chính từ các sàn giao dịch HOSE/HNX để xây dựng một mô hình NLP phiên bản tiếng Việt, trực tiếp phục vụ cho cộng đồng nhà đầu tư trong nước.

TÀI LIỆU THAM KHẢO

- [1] Dữ liệu gốc (Dataset): Malo, P., Sinha, A., Korhonen, P., Wallenius, J., & Takala, P. (2014). *"Good debt or bad debt: Detecting semantic orientations in economic texts"*. Journal of the Association for Information Science and Technology, 65(4), 782-796. (Nguồn cung cấp bộ dữ liệu Financial PhraseBank).
- [2] Nền tảng Học máy (Machine Learning): Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). *"Scikit-learn: Machine learning in Python"*. Journal of machine learning research, 12(Oct), 2825-2830. (Sử dụng cho các mô hình Logistic Regression, SVM, Naive Bayes và TF-IDF).
- [3] Kỹ thuật Tiền xử lý & Biểu diễn ngôn ngữ: Jurafsky, D., & Martin, J. H. (2023). *"Speech and Language Processing (3rd ed. draft)"*. Đại học Stanford. (Tham khảo lý thuyết về N-gram, Bag-of-Words và TF-IDF).
- [4] Kho lưu trữ và Tài liệu Trực tuyến (Websites & Documentation): Hugging Face (2024). *Financial PhraseBank Dataset Repository*. Truy cập tại: https://huggingface.co/datasets/takala/financial_phrasebank
- [5] Xử lý tài liệu PDF (PDF Parsing): Tài liệu chính thức của thư viện PyMuPDF / pdfplumber. Dùng để trích xuất văn bản từ Báo cáo thường niên (Annual Reports). Truy cập tại hệ thống tài liệu chuẩn của Python (PyPI).
- [6] Khung phát triển Ứng dụng Web (Web Application Framework): Tài liệu chính thức của *Streamlit / Flask* (Tùy thuộc vào công cụ nhóm bạn chọn để Deploy Web). Hướng dẫn tích hợp mô hình Machine Learning (.pkl) vào giao diện Web tương tác.